

# 2

## TensorFlow 中的数据流编程

**Keras** 是一个紧凑且易于学习的深度学习高级 Python 库，可以在 **TensorFlow**（或 **Theano** 或 **CNTK**）之上运行。它允许开发人员专注于深度学习的主要概念，如为神经网络创建层，同时照顾到张量、其形状和数学细节的琐碎细节。**TensorFlow**（或 **Theano** 或 **CNTK**）必须是 **Keras** 的后端。你可以在不与相对复杂的 **TensorFlow**（或 **Theano** 或 **CNTK**）互动的情况下将 **Keras** 用于深度学习应用。有两种主要的框架：顺序性 API 和功能性 API。顺序 API 是基于层的序列的想法；这是 **Keras** 最常见的用法，也是 **Keras** 最简单的部分。顺序模型可以被认为是一个线性的层堆叠。

简而言之，你创建一个序列模型，你可以很容易地添加层，每个层都可以有卷积、最大池化、激活、丢弃和批量规范化。让我们看看在 **Keras** 中开发深度学习模型的主要步骤。

### 2.1. 深度学习模型的主要步骤

**Keras** 中的深度学习模型的四个核心部分如下：

1. 定义模型：在这个阶段，你创建一个序列模型并添加层。每个层可以包含一个或多个卷积、池化、批量归一化和激活函数。
2. 编译模型：这里你在调用模型的 `compile()` 函数之前应用损失函数和优化器。
3. 用训练数据拟合模型。在这里，你通过调用模型的 `fit()` 函数在测试数据上训练模型。
4. 进行预测。在这里，你通过调用 `evaluate()` 和 `predict()` 等函数，使用模型在新的数据上生成预测。

**Keras** 中的深度学习过程有八个步骤。

1. 加载数据。
2. 预处理数据。
3. 定义模型。
4. 编译模型。
5. 拟合模型。

6. 评估模型。
7. 进行预测。
8. 保存模型。

### 2.1.1. 加载数据

如何加载数据的过程如下：

**Listing 2.1:** 导入模块

```
1 # Importing modules
2 import numpy as np
3 import os
4 from keras. datasets import cifar10
5 from keras. models import Sequential
6 from keras. layers. core import Dense, Dropout, Activation
7 from keras.optimizers import adam
8 from keras.utils import np_utils
```

**Listing 2.2:** 加载数据

```
1 #Load Data
2 np.random. seed(100) # for reproducibility
3 (X_train, y_train), (X_test, y_test) = cifar10.load_data()
4 #cifar-10 has images of airplane, automobile, bird, cat,
5 # deer, dog, frog, horse, ship and truck ( 10 unique Labels)
6 # For each image. width = 32, height =32, Number of channels (RGB) = 3
```

### 2.1.2. 预处理数据

以下是你如何预处理数据：

**Listing 2.3:** 预处理数据

```
1 #预处理数据
2 #Flatten the data, MLP doesn't use the 2D structure of the data. 3072 = 3*32*32
3 X_train = X_train. reshape(50000, 3072) # 50,000 images for training
4 X_test = X_test. reshape(10000, 3072) # 10,000 images for test
5 # Gaussian Normalization( Z- score)
6 X_train
7 (X_train- np.mean(X_train))/np.std(X_train)
8 X_test = (X_test- np.mean(X_test))/np.std(X_test)
```

**Listing 2.4:** 将类向量转换为二进制类矩阵 (如 one-hot 向量)

```
1 # 将类向量转换为二进制类矩阵 (如 one-hot 向量)
2 labels
3 10 #10 unique Labels(0-9)
4 Y_train
5 np_utils. to_categorical(y_train, labels)
6 Y_test = np_utils. to_categorical(y_test, labels)
```

### 2.1.3. 定义模型

Keras 中的序列模型被定义为一个层的序列。你创建一个序列模型，然后添加层。你需要确保输入层有正确的输入数量。假设你有 3,072 个输入变量；那么你需要用 512 个节点/神经元创建一个隐藏层。在第二个隐藏层中，你有 120 个节点/神经元。最后，你在输出层有十个节点。例如，一幅图像映射到十个节点上，显示出成为 label1 (airplane)、label2 (automobile)、label3 (cat)、...、label10 (truck) 的概率。概率最高的节点是预测的类别/标签。

Listing 2.5: 定义模型的架构

```
1 # 定义模型的架构
2 model = Sequential()
3 model.add(Dense(512, input_shape=(3072,))) # 3*32*32
4 3072
5 model.add(Activation('relu'))
6 model.add(Dropout(0.4)) # Regularization
7 model.add(Dense(120))
8 model.add(Activation('relu'))
9 model.add(Dropout(0.2)) # Regularization
10 model.add(Dense(labels)) # Last Layer with 10 outputs, each output per class
11 model.add(Activation('sigmoid'))
```

一幅图像有三个通道 (RGB)，在每个通道中，图像有  $32 \times 32 = 1024$  像素。因此，每幅图像有  $3 \times 1024 = 3072$  个像素 (特征/X/输入)。在 3072 个特征的帮助下，你需要预测标签 1 (数字 0)、标签 2 (数字 1) 的概率，以此类推。这意味着该模型预测了 10 个输出 (数字 0-9)，每个输出代表相应标签的概率。最后一个激活函数 (sigmoid，如前所示) 对九个输出给出 0，对一个输出给出 1。这个标签就是图像的预测类别 (图 2-1)。例如，3,072 个特征  $\Rightarrow$  512 节点  $\Rightarrow$  120 节点  $\Rightarrow$  10 节点。

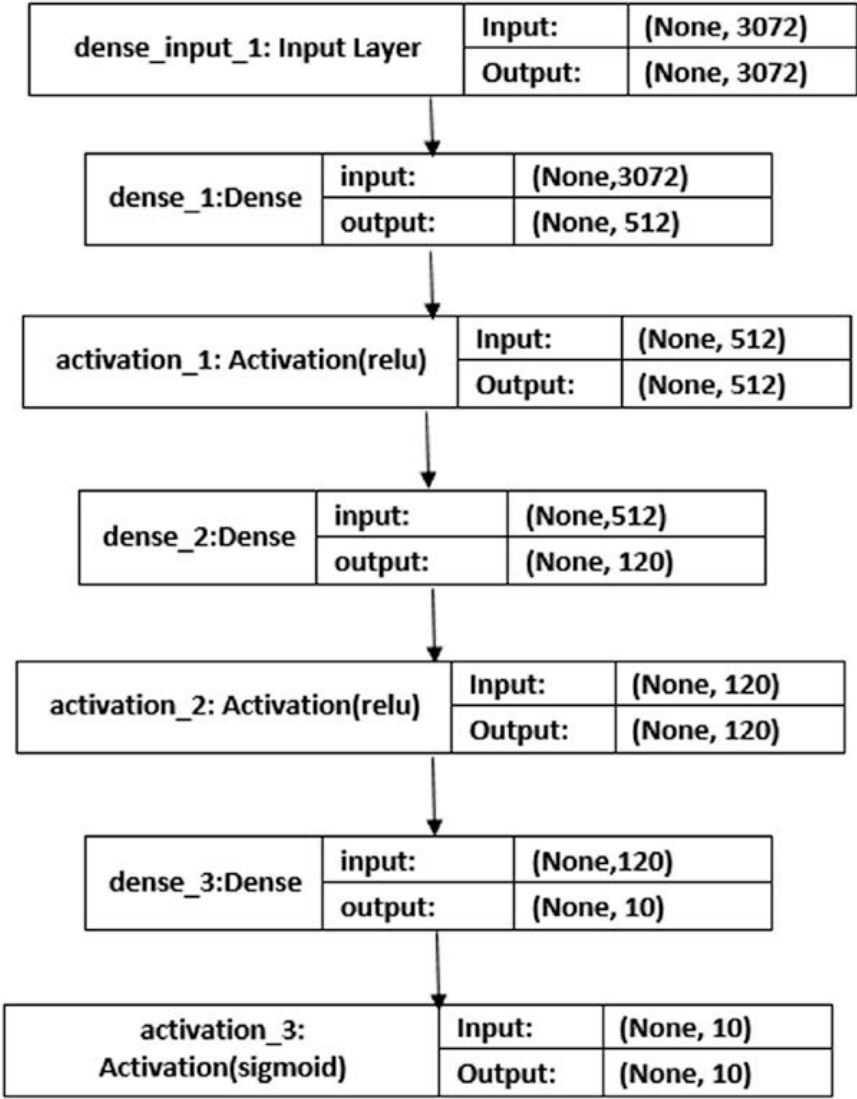


图 2.1: 定义模型

下一个问题是，你如何知道要使用的层数和它们的类型？没有人有确切的答案。对于评估指标来说，最好的办法是由你决定最佳的层数以及每层的参数和步骤。也有采用启发式方法的。最佳的网络结构是通过试错实验的过程找到的。一般来说，你需要一个足够大的网络来捕捉问题的结构。

在这个例子中，你将使用一个有三层的全连接网络结构。一个密集类定义了全连接层。在这种情况下，你将网络权重初始化为一个从均匀分布（uniform）中生成的小的随机数，在这种情况下是在 0 和 0.05 之间，因为这是 Keras 中默认的统一权重初始化。另一个传统的选择是正常的从高斯分布生成的小随机数。你使用或扣到默认阈值为 0.5 的任一类别的硬分类。你可以通过添加每一层来拼凑它。

2.1.4. 编译模型

Listing 2.6: 编译模型

```

1 # Compile the model
2 # Use adam as an optimizer
3 adam = adam(0.01)
4 # the cross entropy between the true Label and the output (softmax) of the model
5 model.compile(loss='categorical_crossentropy', optimizer=adam, metrics=["accuracy"])

```

流行的损失函数有二元交叉熵、分类交叉熵、平均-平方-对数-误差(mean\_squared\_logarithmic\_error)和铰链损失。流行的优化器有随机梯度下降 (SGD)、RMSProp、adam、adagrad 和 adadelta。流行的评估指标是准确性、召回率和 F1 分值。

简而言之，这一步的目的是通过迭代来调整基于损失函数的权重和偏置，基于优化器的评估指标，如准确性。

### 2.1.5. 适配模型

在定义和编译了模型之后，你需要通过在一些数据上执行模型来进行预测。在这里，你需要指定 **epochs**；这些是训练过程在数据集中运行的迭代次数，以及批次大小，也就是在权重更新前评估的实例数量。对于这个问题，程序将运行少量的历时（10），在每个历时中，它将完成 50 (=50,000/1,000) 次迭代，其中批次大小为 1,000，训练数据集有 50000 个实例/图像。同样，没有硬性规定来选择批次大小。但它不应该非常小，而且应该远远小于训练数据集的大小，以减少内存消耗。

```

#make the model learn ( Fit the model)
model.fit(X_train, Y_train, batch_size=1000, nb_epoch=10, validation_data=(X_test, Y_test))

Train on 50000 samples, validate on 10000 samples
Epoch 1/10
1000/50000 [.....] - ETA: 6s - loss: 2.3028 - acc: 0.1060

C:\ProgramData\Anaconda3\lib\site-packages\keras\models.py:848: UserWarning: The 'nb_epoch' argument in 'fit' has been renamed
'epochs'.
  warnings.warn('The `nb_epoch` argument in `fit` '

50000/50000 [=====] - 6s - loss: 2.3030 - acc: 0.0974 - val_loss: 2.3027 - val_acc: 0.1000
Epoch 2/10
50000/50000 [=====] - 7s - loss: 2.3029 - acc: 0.1012 - val_loss: 2.3027 - val_acc: 0.1000
Epoch 3/10
50000/50000 [=====] - 7s - loss: 2.3028 - acc: 0.0972 - val_loss: 2.3026 - val_acc: 0.1000
Epoch 4/10
50000/50000 [=====] - 7s - loss: 2.3028 - acc: 0.0997 - val_loss: 2.3027 - val_acc: 0.1000
Epoch 5/10
50000/50000 [=====] - 7s - loss: 2.3029 - acc: 0.0975 - val_loss: 2.3027 - val_acc: 0.1000
Epoch 6/10
50000/50000 [=====] - 7s - loss: 2.3029 - acc: 0.0986 - val_loss: 2.3028 - val_acc: 0.1000
Epoch 7/10
50000/50000 [=====] - 7s - loss: 2.3029 - acc: 0.0995 - val_loss: 2.3028 - val_acc: 0.1000
Epoch 8/10
50000/50000 [=====] - 7s - loss: 2.3028 - acc: 0.0983 - val_loss: 2.3027 - val_acc: 0.1000
Epoch 9/10
50000/50000 [=====] - 7s - loss: 2.3029 - acc: 0.0998 - val_loss: 2.3027 - val_acc: 0.1000
Epoch 10/10
50000/50000 [=====] - 7s - loss: 2.3029 - acc: 0.0972 - val_loss: 2.3027 - val_acc: 0.1000

<keras.callbacks.History at 0x2870136ef0>

```

图 2.2: Fit the Model

### 2.1.6. 评估模型

在训练数据集上训练好神经网络后，你需要评估网络的性能。请注意，这只能让你知道你对数据集的建模效果如何（例如，训练准确率），但你不会知道算法在新数据上的表现可能如何。这是为了简单起见，但理想情况下，你可以将你的数据分成训练和测试数据集，用于训练和评估你的模型。你可以在你的训练数据集上使用 **evaluation()** 函数来评估你的模型，并将用于训练模型的相同输入和输出传递给它。这将为每个输入和输出生成一个预测，并收集分数，包括平均损失和你配置的任何指标，如准确性。

**Listing 2.7:** 评估模型在测试集上的表现

```
1 #Evaluate how the model does on the test set
2 score = model.evaluate (X_test, Y_test, verbose=0)
3 #Accuracy Score
4 print ('Test accuracy:', score[1])
```

### 2.1.7. 预测

一旦你建立并评估了模型，你需要对未知数据进行预测。

**Listing 2.8:** 对未知数据进行预测

```
1 #Predict digit(0-9) for test Data
2 model.predict_classes(x_test)
```

输出

**Listing 2.9:** 结果

```
1 9888/10000 [=====» .] - ETA: 0S
2 array([3, 8, 8,3, 4, 71, dtype=int64])
```

### 2.1.8. 保存并重新加载模型

这里是最后一步。

**Listing 2.10:** 保存模型

```
1 %#Saving the model
2 model.save('model.h5')
3 jsonModel = model.to_json()
4 model.save_weights (*modelweight.h5')
```

**Listing 2.11:** 加载模型

```
1 %#Load weight of the saved model
2 modelwt = model.load_weights ('modelweight.h5')
```

### 2.1.9. 总结模型

现在让我们来看看如何总结模型。

**Listing 2.12:** 模型的摘要

```
1 %#Summary of the model
2 model.summary()
```

```
#Summary of the model
model.summary()
```

Layer (type)	Output Shape	Param #
dense_7 (Dense)	(None, 512)	1573376
activation_7 (Activation)	(None, 512)	0
dropout_5 (Dropout)	(None, 512)	0
dense_8 (Dense)	(None, 120)	61560
activation_8 (Activation)	(None, 120)	0
dropout_6 (Dropout)	(None, 120)	0
dense_9 (Dense)	(None, 10)	1210
activation_9 (Activation)	(None, 10)	0
Total params: 1,636,146		
Trainable params: 1,636,146		
Non-trainable params: 0		

图 2.3: Fit the Model

## 2.2. 改进 Keras 模型的其他步骤

这里还有一些改进你的模型的步骤。1. 有时，由于梯度消失或爆炸，模型建立过程没有完成。如果是这种情况，你应该采取以下措施。

Listing 2.13: 防止梯度消失或者爆炸

```
1 from keras.callbacks import EarlyStopping
2 early_stopping_monitor = EarlyStopping(patience=2)
3 model.fit(x_train, y_train, batch_size=1000, epochs=10,
4 validation_data=(x_test, y_test),
5 callbacks=[early_stopping_monitor])
```

2. 对输出形状进行建模。

Shape of the n-dim array (output of the model  
at the current position)

model.output\_shape

3. 建立总结性表述的模型。

model.summary()

4. 对配置进行建模。

model.get\_config()

5. 列出该模型中的所有权重张量。

model.get\_weights()

以下是 Keras 模型的完整代码。

用 Keras 建立的深度学习模型

import numpy as np

```

from keras. models import Sequential
from keras. layers import Dense
读取数据 data = np.random.random((500,100))
labels = np.random.randint(2,size=(500,1))
建立模型
model = Sequential()
model.add(Dense(12, input_dim=8, activation='relu'))
model.add(Dense(8, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
编译模型
model.compile(loss='binary_crossentropy', optimizer='adam',metrics=['accuracy'])
拟合模型
model. fit(X[train], Y[[train], epochs=150, batch_size=10, verbose=0)
评估该模型
scores = model. evaluate(X[test], Y[test], verbose=0)
print("%s: %.2f%%" % (model.metrics_names[1], scores[1]*100))
cvscores.append(scores[1] * 100) print("%.2f%% (+/- %.2f%%)" %(numpy.mean(cvscores),
numpy.std(cvscores)))) 预测
predictions = model.predict(data)

```

## 2.3. TensorFlow 与 Keras

Keras 通过利用 TensorFlow/Theano 之上的强大而清晰的深度学习库来提供高级神经网络。Keras 是 TensorFlow 的一个重要补充，因为它的层和模型与纯 TensorFlow 的张力兼容。此外，它可以与其他 TensorFlow 库一起使用。

以下是在 TensorFlow 中使用 Keras 的步骤：

1. 首先创建一个 TensorFlow 会话，并将其注册到 Keras。这意味着 Keras 将使用你注册的会话来初始化它内部创建的所有变量。

**Listing 2.14:** 创建一个 TensorFlow 会话，并将其注册到 Keras

```

1 import tensorflow as tf
2 sess = tf.Session()
3 from keras import backend as K
4 K.set_session(sess)

```

2. Keras 模块，如模型、层和激活，被用来建立模型。Keras 引擎会自动将这些模块转换为相当于 TensorFlow 的脚本。

3. 除了 TensorFlow, Theano 和 CNTK 也可以作为 Keras 的后端。

4. TensorFlow 后端有一个惯例，即按照深度、高度、宽度的顺序制作输入形状（给你的网络的第一层），其中深度可以指通道的数量。

5. 你需要正确配置 keras.json 文件，以便它使用 TensorFlow 后端。它应该看起来像这样。

**Listing 2.15:** 使用 TensorFlow 后端

```

1 {

```



```
2     "backend": "theano",  
3     "epsilon": 1e-07,  
4     "image_data_format": "channels_first",  
5     "floatx": "float32"  
6 }
```